

# Lab Report : Image Classification Practice

王浩天 陶昱丞

## Lab Report : Image Classification Practice

### I. 数据处理

### II. 系统设计

#### 1. 模型设计

- A. Shallow CNN
- B. ElexNet : Inspired by AlexNet
- C. ResNet-18

#### 2. 训练方法

### III. 实验结果

#### 1. Shallow CNN

- A. 预测准确率
- B. 训练过程
- C. 调参实验及结果分析

#### 2. ElexNet

- A. 预测准确率
- B. 训练过程
- C. 调参实验及结果分析
  - a.
  - b.
  - c.
  - d.
  - e.
- D. 参数量

#### 3. ResNet-18

- A. 预测准确率
- B. 训练过程
- C. 调参实验及结果分析
  - a.
  - b.
- D. 参数量

# I. 数据处理

为了缓解实验过程中可能出现的过拟合，我们采用了Data Augmentation（数据增量）的方案。在本次实验中，我们采用了transforms操作进行数据增强。

具体地，我们通过概率水平翻转和竖直翻转给定的PIL图像来人工地增大数据集。

```
1 transforms.RandomHorizontalFlip(0.5),  
2 transforms.RandomVerticalFlip(0.5),
```

此外，我们还使用transforms.ToTensor()将数据分布调整到 (0, 1) 之间，并使用Normalize进行计算，将数据归一化到 (-1,1) 之间，从而让数据更加贴合正态分布。

## II. 系统设计

### 1. 模型设计

关于本次大作业的模型设计，从图像分类的任务出发，我们决定选择CNN图像分类算法以及其相关的模型。

首先，我们根据PyTorch的tutorial实现了基础的CNN图像分类算法，设计出了一个具有两个卷积层的卷积神经网络，并对其进行实验测试。经过一段时间的参数调试之后，我们发现，这个模型不能满足我们的作业要求，虽然这个模型的较为简单，训练用时也非常短，但是这个简单的CNN模型在Cifar-10数据集上训练后进行测试的准确率仅有55%左右。

在此基础上，我们调研了当前学术界较为知名、用途广泛的各种CNN模型，例如AlexNet、VGG、ResNet、GoogLeNet等。经过广泛地调研和阅读，我们决定在AlexNet的基础上，根据Cifar-10数据集的特征，实现自己的CNN模型。在完成自己的模型之后，我们还进行了一系列的模型优化和参数调试，最终能够达到大约79%的准确率。这个结果相比于最初的模型已经有了很大的提升，在Cifar-10数据测试集上图像分类的效果很好。

但是，这还是没有达到我们的预期目标，为了使我们的实验结果更进一步，达到更为精确的图像分类效果，我们又转而采用当前学术界和工业界广泛使用的ResNet残差网络模型，经过代码实现，最终在Cifar-10数据测试集上达到92.35%的测试准确率。这个结果超出我们的预期，完全实现了我们对于此次项目的目标。

下面，我们会一一介绍上述提到的各个模型。


#### A. Shallow CNN

Shallow CNN model是我们最开始尝试的模型，它的网络设计和PyTorch官方的CNN tutorial给出的模型是一致的，输入 $32 * 32 * 3$ 的RGB三通道图片，经过两个卷积层、两个池化层、两个非线性激活层，经过Flatten连接到三个全连接层，将最终结果映射到 $10 * 1$ 的向量进行label的判断，损失函数采用常用的交叉熵，利用随机梯度下降进行参数更新。

这个卷积神经网络只有两个卷积层，卷积核大小分别为 $5 * 5$ 和 $5 * 5$ 。网络的效果非常差，在 $EPOCH = 100$   $LR = 0.001$ 的条件下训练出的模型在Cifar-10的准确率只有55%左右。

分析其效果不佳的原因，我们认为这个网络只有两个卷积层，且每个卷积层的卷积核数量非常少，无法提取到足够的图像信息。而且在Cifar-10数据集本身图像较小的情况下，经过两个MaxPool池化层处理，损失了较多图像信息。另外，这个模型没有正则化，容易导致梯度爆炸和梯度消失，导致反向传播和参数更新的效果不佳。

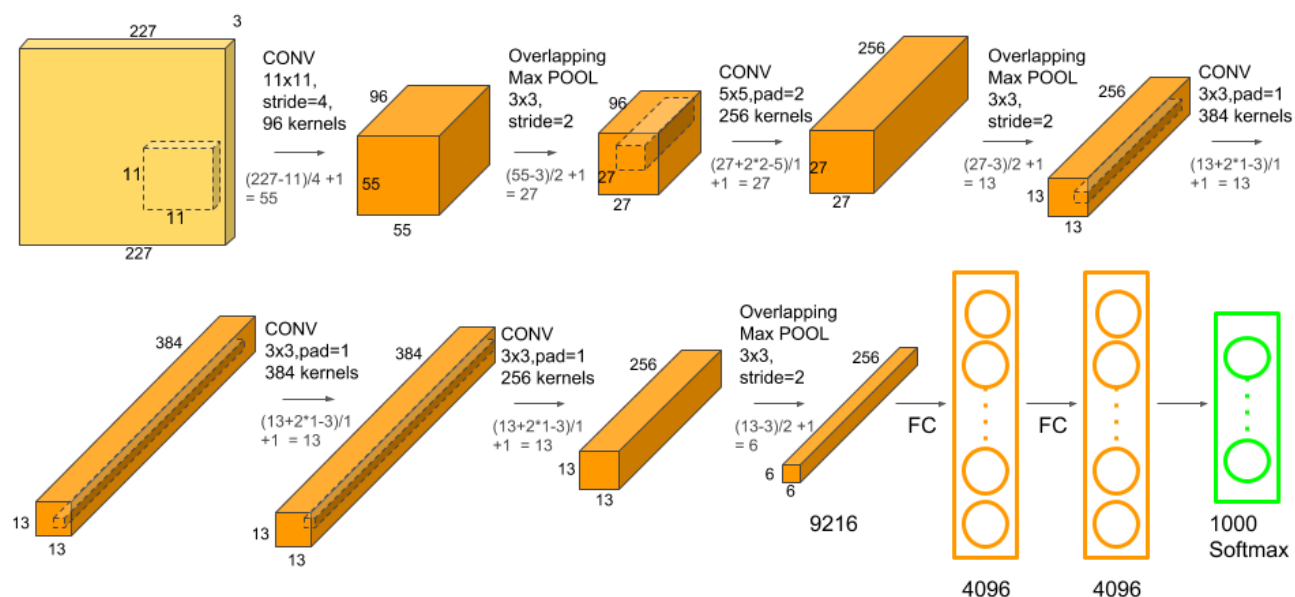
以上都是导致这个模型效果不佳的原因，对此，我们汲取了深刻的经验教训。



## B. ElexNet : Inspired by AlexNet


在经历了Shallow CNN的失败后，我们从中总结经验教训，考虑从卷积层数量、池化层位置、正则化等方面入手，设计更加优化的模型，以期得到更好的实验结果。

在查阅了论文和资料后，我们了解了当前学术界和工业界一些主流CNN算法的实现，例如AlexNet、VGG、ResNet，GoogLeNet等。这些模型都在卷积层、卷积核等很多方面做了优化。在综合评估后，我们决定首先在AlexNet的基础上搭建一个CNN网络。下图是AlexNet的模型结构。



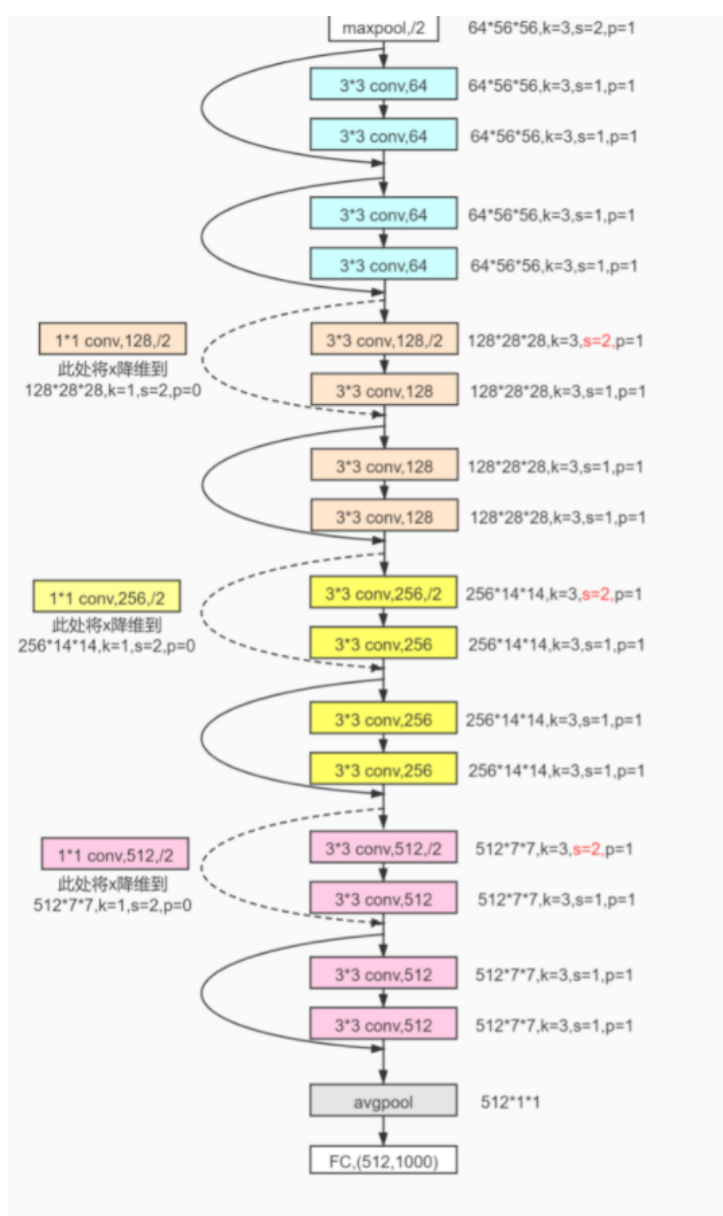
在AlexNet的启发下，我们搭建了自己的模型，并将其命名为ElexNet。考虑到Cifar-10数据集图片本身尺寸很小的特点，我们并没有完全按照AlexNet论文的描述实现卷积神经网络，而是根据测试效果，调整了卷积核的大小，使其更加适应数据集的特点。另外，我们还删除了第一个卷积层Conv1之后的池化层Overlapping Max Pool，原因是Cifar-10数据集尺寸过小，经过池化层处理后会损失很多信息。经过测试，我们还修改了一些对模型结果影响不大的结构，以加快拟合速度。

最终，ElexNet在Cifar-10测试集上的测试准确率为79%，这个效果相比与Shallow CNN有了很大的提升。



## C. ResNet-18

经历了ElexNet的成功，我们仍然觉得79%的测试准确率仍然有些低。这时，我们将目光投向了被称为CNN图像史上里程碑的ResCNN，期望能达到更高的准确率。根据ResNet论文中给出的结构列表，我们搭建了18层的RNN网络。下图是ResNet-18模型的详细结构。



ResNet-18由17层卷积层和1个全连接层组成。网络中存在两种不同的基本块：一种是在通道数不变的情况下，进行的残差结构运算，如上图实线标注的跳跃连接部分；另一种则是在进行残差结构运算时，发生了通道数改变，如上图虚线部分所示。我们分别将他们作为不同的基本块。在卷积操作都完成后，通过平均池化avgpool层最终到达全连接层。此外我们还对图像预处理的参数进行了一些优化，使得数据分布更加正则。

在最后的测试中，ResNet-18在Cifar-10测试集上的准确率最高可以达到92.35%，相比之前的两种模型而言可以说是有了质的飞跃。

## 2. 训练方法

我们首先使用torchvision加载了CIFAR10训练集和测试集，并对数据集做了归一化处理。对于训练集，我们还使用transforms进行了Data Augmentation来缓解可能出现的过拟合。

之后我们创建了Convolutional Neural Network，并使用交叉熵来评估loss，定义了loss function。

紧接着，我们在GPU上使用自己定义的network进行迭代计算。从训练集中不断取出样本输入到网络中，计算出实际的输出和理想输出的差，即loss，打印出loss并绘制loss图像用于辅助分析，并按照极小化误差的方法反向传播调整权矩阵。经过100次epoch后结束训练。

训练完成后，我们将测试集输入到所得的模型中，将输出结果与真实值比较，并记录下模型的预测准确率。

接下来，我们通过不断更新network的模型和参数一次次进行训练和迭代。最终，我们筛选出预测准确率最高的模型和参数设置。

## III. 实验结果

### 1. *Shallow CNN*

#### A. 预测准确率

Shallow CNN的准确率在最好情况下只有55%

#### B. 训练过程

我们对Shallow CNN的模型进行搭建之后，设置Batch Size=256 EPOCH=100进行训练，每次训练用时大概为20s。

## C. 调参实验及结果分析

```
class Net(nn.Module):
    def __init__(self):
        super().__init__()
        self.conv1 = nn.Conv2d(3, 6, 5)
        self.pool = nn.MaxPool2d(2, 2)
        self.conv2 = nn.Conv2d(6, 16, 5)
        self.fc1 = nn.Linear(16 * 5 * 5, 120)
        self.fc2 = nn.Linear(120, 84)
        self.fc3 = nn.Linear(84, 10)

    def forward(self, x):
        x = self.pool(F.relu(self.conv1(x)))
        x = self.pool(F.relu(self.conv2(x)))
        x = torch.flatten(x, 1) # flatten all dimensions except batch
        x = F.relu(self.fc1(x))
        x = F.relu(self.fc2(x))
        x = self.fc3(x)
        return x
```

我们调整了多组Batch Size、Kernel Size等参数，模型准确率均没有太大变化。

由于这个模型只有两层卷积层，卷积核尺寸也非常小，对于图像信息的提取能力非常弱。考虑到模型的这些固有缺陷制约了准确率的提高，无论如何调整参数都不可能达到较好的效果，因此我们在这个模型上并没有耗费太多时间。


## 2. ElexNet

### A. 预测准确率

ElexNet在最佳情况下的预测准确率为79%

### B. 训练过程

下图给出了**最终版本**ElexNet在最佳情况时的loss变化，从图中可以看到，在训练的初始阶段，loss下降很快，随着epoch增加，loss下降的速度逐渐降低，并最终趋于平稳。



## C. 调参实验及结果分析

针对ElexNet模型，我们对其网络结构进行了一些列调整，以达到更好的训练效果。

a.

下图为最初版本ElexNet的模型参数，在这组模型参数下调整Batch Size，以epoch=100的条件运行，得到的结果在Cifar-10测试集上的准确率为70%

```
25 class Net(nn.Module):
26
27     def __init__(self):
28         super().__init__()
29         self.conv1 = nn.Conv2d(3, 16, kernel_size=(7, 7))
30         self.relu1 = nn.ReLU()
31         self.bn1 = nn.BatchNorm2d(16)
32         self.max_pool_1 = nn.MaxPool2d(3, 2)
33
34         self.conv2 = nn.Conv2d(16, 32, kernel_size=(5, 5), stride=(1, 1), padding=(2, 2))
35         self.relu2 = nn.ReLU()
36         self.bn2 = nn.BatchNorm2d(32)
37         self.max_pool_2 = nn.MaxPool2d(3, 2)
38
39         self.conv3 = nn.Conv2d(32, 64, kernel_size=(3, 3), stride=(1, 1), padding=(1, 1))
40         self.relu3 = nn.ReLU()
41
42         self.conv4 = nn.Conv2d(64, 128, kernel_size=(3, 3), stride=(1, 1), padding=(1, 1))
43         self.relu4 = nn.ReLU()
44
45         self.conv5 = nn.Conv2d(128, 96, kernel_size=(3, 3), stride=(1, 1), padding=(1, 1))
46         self.relu5 = nn.ReLU()
47
48         self.max_pool_3 = nn.MaxPool2d(2, 2)
49
50         self.fc1 = nn.Linear(96 * 2 * 2, 384)
51         self.fc2 = nn.Linear(384, 144)
52         self.fc3 = nn.Linear(144, 10)
53
```

plane	car	bird	cat	deer	dog	frog	horse	ship	truck	total
72.1%	84.1%	71.4%	53.8%	64.8%	62.9%	76.4%	74.5%	72.9%	75.9%	70%

总体准确率为70%，在cat类别上的预测准确率非常低。

考虑到这个模型已经有足够的深度，受到计算资源的限制，继续增加深度会带来很多的训练时间增长，我们考虑从卷积核数量入手，在卷积层增加卷积核的数量，以期达到更好的训练效果。

## b.

针对上述问题，我们调整了模型参数，作出一些改进，在对每个卷积层都增加了卷积核的数量，使用更多的参数进行非线性函数的拟合。

```

class Net(nn.Module):
    def __init__(self):
        super().__init__()
        self.conv1 = nn.Conv2d(3, 16, kernel_size=(7, 7))
        self.relu1 = nn.ReLU()
        self.bn1 = nn.BatchNorm2d(16)
        self.max_pool_1 = nn.MaxPool2d(3, 2)

        self.conv2 = nn.Conv2d(16, 64, kernel_size=(5, 5), stride=(1, 1), padding=(2, 2))
        self.relu2 = nn.ReLU()
        self.bn2 = nn.BatchNorm2d(64)
        self.max_pool_2 = nn.MaxPool2d(3, 2)

        self.conv3 = nn.Conv2d(64, 128, kernel_size=(3, 3), stride=(1, 1), padding=(1, 1))
        self.relu3 = nn.ReLU()

        self.conv4 = nn.Conv2d(128, 256, kernel_size=(3, 3), stride=(1, 1), padding=(1, 1))
        self.relu4 = nn.ReLU()

        self.conv5 = nn.Conv2d(256, 192, kernel_size=(3, 3), stride=(1, 1), padding=(1, 1))
        self.relu5 = nn.ReLU()

        self.max_pool_3 = nn.MaxPool2d(2, 2)

        self.fc1 = nn.Linear(192 * 2 * 2, 768)
        self.fc2 = nn.Linear(768, 96)
        self.fc3 = nn.Linear(96, 10)

```

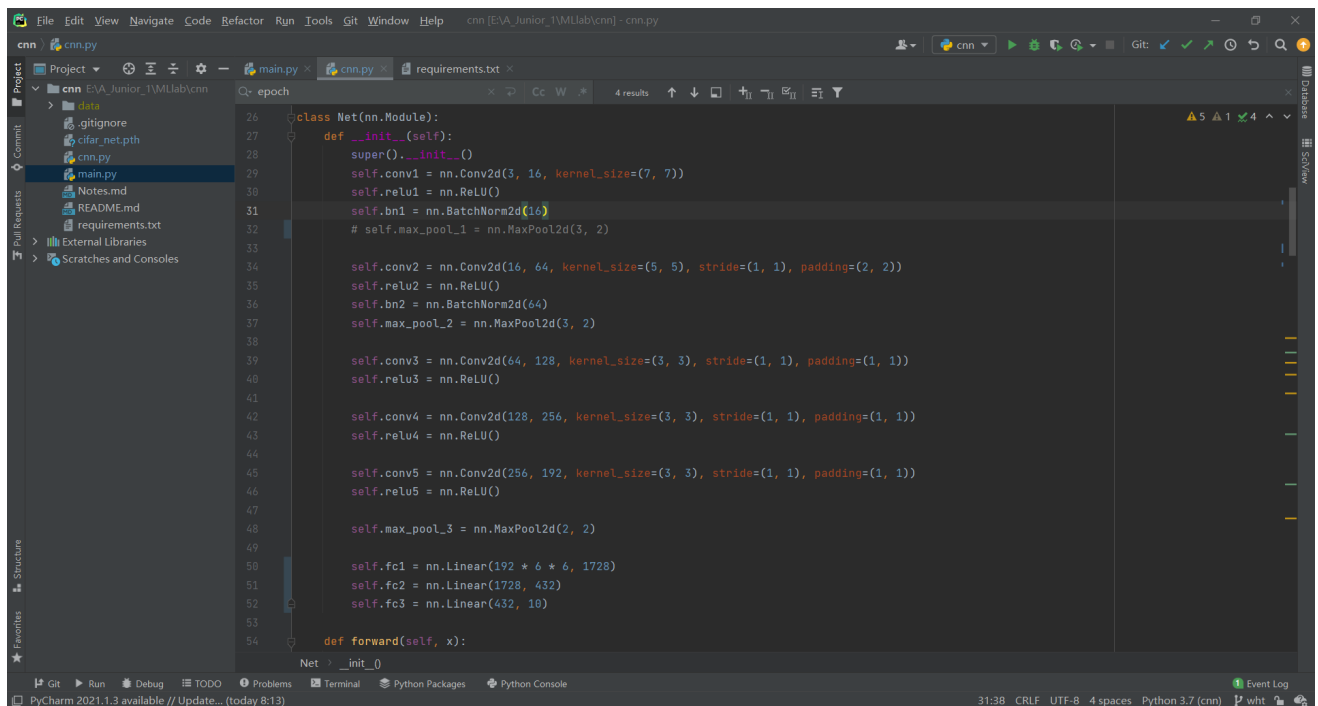
plane	car	bird	cat	deer	dog	frog	horse	ship	truck	total
78.6%	81.4%	51.9%	60.3%	71.8%	64.2%	77.6%	76.3%	82.5%	81.9%	72%

总体预测准确率达到72%，相比于原始模型上升了2%。在细分种类中，对于ship、truck、plane的分类能力显著提升，但是对于bird的分类能力降低较多。虽然准确率有所上升，但是仍然没有达到我们的预期。还需要继续改进模型。

## c.

考虑到Cifar-10数据集的自身尺寸小的特点，我们进行了针对性的调整，删除了第一个卷积层后的池化层，原因是Cifar-10本身为 $32 * 32 * 3$ ，在小尺寸的数据集上进行池化会损失较多图片信息。删除第一层池化层之后，模型对于图像细节信息的提取更强，可以提高分类能力。



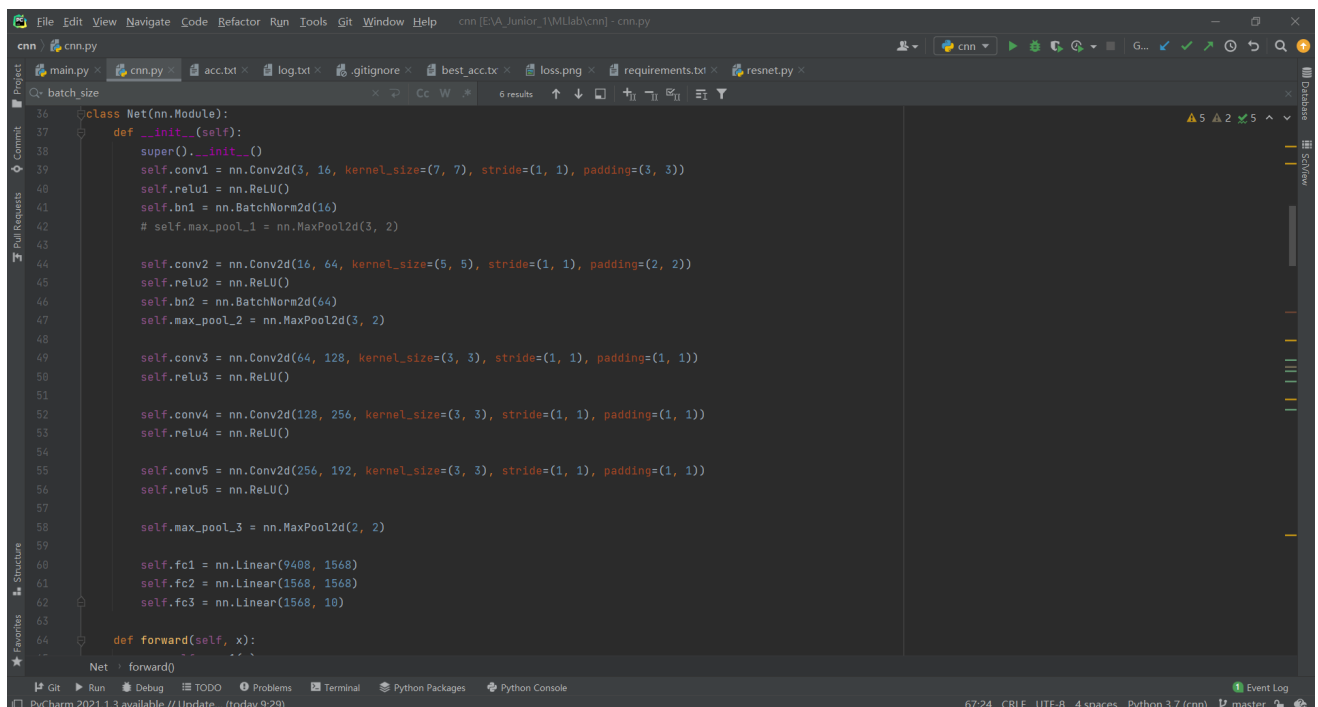


plane	car	bird	cat	deer	dog	frog	horse	ship	truck	total
80.8%	86.5%	68.6%	61.1%	75.4%	68.2%	84.6%	80.7%	85.0%	84.2%	77%

可以看到，删除了第一层池化层之后，模型分类准确率提升显著，从72%上升至77%。在各个细分种类的分类能力也均有所提升。这说明我们的优化思路是正确的，模型对于细节信息的提取能力大大增强。

#### d.

为了进一步优化分类效果，我们又对这个模型进行了探究。经过仔细探究发现，第一层的卷积层中stride=1 kernel\_size=7 padding=0，这样的卷积核参数导致我们损失了图像边缘的部分信息，为此我们再次修改参数，为第一层卷积层增加大小为3的padding，以便充分利用边缘的信息。在这样的参数条件下，模型的预测准确率达到79%，相较于不加padding提升了2%。



e.


此外，我们还调整了学习率分别进行了多次测试

学习率	0.0008	0.001	0.0012	0.0014	0.0016	0.0018
准确率	76%	79%	78%	76%	76%	78%


最终发现当学习率为0.001时，准确率以微弱的优势胜出。而在这几组实验中，loss图像相差微乎其微，肉眼几乎无法观察出其差别，因而我们认为其图像近似相同。最终，我们觉得选用准确率最高的那组参数，即学习率为0.001。

下面，依次给出不同学习率的loss图像：


学习率=0.0008时




学习率=0.001时




学习率=0.0012时




学习率=0.0014时



学习率=0.0016时



学习率=0.0018时



## D. 参数量

以最终版本的ElexNet为准，这个模型的参数量还是十分可观的，也正是这么多的参数量带来了模型精度的提升。

1	-----
2	Layer (type) Output Shape Param #
3	=====
4	Conv2d-1 [500, 16, 32, 32] 2,368
5	ReLU-2 [500, 16, 32, 32] 0
6	BatchNorm2d-3 [500, 16, 32, 32] 32
7	Conv2d-4 [500, 64, 32, 32] 25,664
8	ReLU-5 [500, 64, 32, 32] 0
9	BatchNorm2d-6 [500, 64, 32, 32] 128
10	MaxPool2d-7 [500, 64, 15, 15] 0
11	Conv2d-8 [500, 128, 15, 15] 73,856
12	ReLU-9 [500, 128, 15, 15] 0
13	Conv2d-10 [500, 256, 15, 15] 295,168
14	ReLU-11 [500, 256, 15, 15] 0
15	Conv2d-12 [500, 192, 15, 15] 442,560
16	ReLU-13 [500, 192, 15, 15] 0
17	MaxPool2d-14 [500, 192, 7, 7] 0
18	Linear-15 [500, 1568] 14,753,312
19	Linear-16 [500, 1568] 2,460,192
20	Linear-17 [500, 10] 15,690
21	=====


## 3. ResNet-18

## A. 预测准确率


ResNet-18在最佳情况下的预测准确率高达92.35%

## B. 训练过程

下图给出了**最终版本**ResNet-18在最佳情况时的loss变化，从图中可以看到，在训练之初，loss下降很快，随着epoch不断增大，loss下降速度逐渐放缓，并最终趋于平稳状态。



下图给出了**最终版本**ResNet-18在最佳情况时测试准确率的变化，从图中可以看到，在训练开始之初，随着epoch的增加，训练集的测试准确率和测试集的测试准确率都在迅速增加，而后两组数据集的准确率增长速度几乎同时放缓，并在不断波动的同时继续增大，最后趋于平稳。其中，测试集的测试准确率增长速度放缓更为明显，波动也更为剧烈，且随着epoch的继续增加，波动的幅度也越来越小，并且最终稳定在了90%以上。



## C. 调参实验及结果分析

a.

针对ResNet18，我们调整了模型的学习率进行测试，但是结果没有显著差异，因此不在此赘述

Residual Block:

```
1 class ResidualBlock(nn.Module):
2     def __init__(self, in_channel, out_channel, stride=1):
3         super(ResidualBlock, self).__init__()
4         self.left = nn.Sequential(
5             nn.Conv2d(in_channel, out_channel, kernel_size=(3, 3), stride=(stride, stride),
6 padding=(1, 1), bias=False),
7             nn.BatchNorm2d(out_channel),
8             nn.ReLU(inplace=True),
9             nn.Conv2d(out_channel, out_channel, kernel_size=(3, 3), stride=(1, 1), padding=
10 (1, 1), bias=False),
11             nn.BatchNorm2d(out_channel)
12         )
13         self.shortcut = nn.Sequential()
14         if stride != 1 or in_channel != out_channel:
15             self.shortcut = nn.Sequential(
16                 nn.Conv2d(in_channel, out_channel, kernel_size=(1, 1), stride=(stride,
17 stride), bias=False),
18                 nn.BatchNorm2d(out_channel)
19             )
```

```

18     def forward(self, x):
19         out = self.left(x)
20         out += self.shortcut(x)
21         out = F.relu(out)
22         return out

```

ResNet main body:

```

1  class ResNet(nn.Module):
2      def __init__(self, residual_block, num_classes=10):
3          super(ResNet, self).__init__()
4          self.in_channel = 64
5          self.conv1 = nn.Sequential(
6              nn.Conv2d(3, 64, kernel_size=(3, 3), stride=(1, 1), padding=(1, 1), bias=False),
7              nn.BatchNorm2d(64),
8              nn.ReLU(),
9          )
10         self.layer1 = self.make_layer(residual_block, 64, 2, stride=1)
11         self.layer2 = self.make_layer(residual_block, 128, 2, stride=2)
12         self.layer3 = self.make_layer(residual_block, 256, 2, stride=2)
13         self.layer4 = self.make_layer(residual_block, 512, 2, stride=2)
14         self.fc = nn.Linear(512, num_classes)
15
16     def make_layer(self, block, channels, num_blocks, stride):
17         strides = [stride] + [1] * (num_blocks - 1) # strides=[1,1]
18         layers = []
19         for stride in strides:
20             layers.append(block(self.in_channel, channels, stride))
21             self.in_channel = channels
22         return nn.Sequential(*layers)
23
24     def forward(self, x):
25         out = self.conv1(x)
26         out = self.layer1(out)
27         out = self.layer2(out)
28         out = self.layer3(out)
29         out = self.layer4(out)
30         out = F.avg_pool2d(out, 4)
31         out = out.view(out.size(0), -1)
32         out = self.fc(out)
33         return out

```

## b.

为了获得更高的准确率，我们还对预处理的正则化参数进行了修改。我们认为原先的默认参数`mean=[0.5, 0.5, 0.5]`, `std=[0.5, 0.5, 0.5]`不够精准，因此自己对训练集中的图像数据进行处理，求出了他们的平均值和标准差（这部分代码详见`calc_mean_std.py`文件中），得到的结果为`mean=[0.4940, 0.4849, 0.4495]`，`std=[0.2014, 0.1985, 0.2001]`，我们将这组数据代入图片数据预处理中，然后进行训练，最终得到的测试集准确率为90.79%。

超过90%的准确率让我们大受鼓舞，但我们仍然期望能在此基础上有所精进。于是我们仔细查找了一些使用ResNet处理Cifar-10数据集的论文和帖子，发现他们普遍提到的一组正则化参数是`mean=[0.485, 0.456, 0.406]`，`std=[0.229, 0.224, 0.225]`，我们尝试将这组数据应用到正则化处理中，最终得到的测试集准确率为91.41%。

我们继续在网络上查找相关的资料，偶然发现有一篇帖子指出当`mean=[0.4914, 0.4822, 0.4465]`，`std=[0.2023, 0.1994, 0.2010]`可以获得更高的测试准确率，但没有给出相应的理论依据。我们将信将疑，将数据代入模型训练中。意外的是，我们的测试准确率竟然真的有了进一步的提升，达到了92.35%。

mean

std

accuracy

mean	std	accuracy
[0.4940, 0.4849, 0.4495]	[0.2014, 0.1985, 0.2001]	90.79%
[0.485, 0.456, 0.406]	[0.229, 0.224, 0.225]	91.41%
[0.4914, 0.4822, 0.4465]	[0.2023, 0.1994, 0.2010]	92.35%

## D. 参数量

1	-----
2	Layer (type) Output Shape Param #
3	=====
4	Conv2d-1 [500, 64, 32, 32] 1,728
5	BatchNorm2d-2 [500, 64, 32, 32] 128
6	ReLU-3 [500, 64, 32, 32] 0
7	Conv2d-4 [500, 64, 32, 32] 36,864
8	BatchNorm2d-5 [500, 64, 32, 32] 128
9	ReLU-6 [500, 64, 32, 32] 0
10	Conv2d-7 [500, 64, 32, 32] 36,864
11	BatchNorm2d-8 [500, 64, 32, 32] 128
12	ResidualBlock-9 [500, 64, 32, 32] 0
13	Conv2d-10 [500, 64, 32, 32] 36,864
14	BatchNorm2d-11 [500, 64, 32, 32] 128
15	ReLU-12 [500, 64, 32, 32] 0
16	Conv2d-13 [500, 64, 32, 32] 36,864
17	BatchNorm2d-14 [500, 64, 32, 32] 128
18	ResidualBlock-15 [500, 64, 32, 32] 0
19	Conv2d-16 [500, 128, 16, 16] 73,728
20	BatchNorm2d-17 [500, 128, 16, 16] 256
21	ReLU-18 [500, 128, 16, 16] 0
22	Conv2d-19 [500, 128, 16, 16] 147,456
23	BatchNorm2d-20 [500, 128, 16, 16] 256
24	Conv2d-21 [500, 128, 16, 16] 8,192
25	BatchNorm2d-22 [500, 128, 16, 16] 256
26	ResidualBlock-23 [500, 128, 16, 16] 0
27	Conv2d-24 [500, 128, 16, 16] 147,456
28	BatchNorm2d-25 [500, 128, 16, 16] 256
29	ReLU-26 [500, 128, 16, 16] 0
30	Conv2d-27 [500, 128, 16, 16] 147,456
31	BatchNorm2d-28 [500, 128, 16, 16] 256
32	ResidualBlock-29 [500, 128, 16, 16] 0
33	Conv2d-30 [500, 256, 8, 8] 294,912
34	BatchNorm2d-31 [500, 256, 8, 8] 512
35	ReLU-32 [500, 256, 8, 8] 0
36	Conv2d-33 [500, 256, 8, 8] 589,824
37	BatchNorm2d-34 [500, 256, 8, 8] 512
38	Conv2d-35 [500, 256, 8, 8] 32,768
39	BatchNorm2d-36 [500, 256, 8, 8] 512
40	ResidualBlock-37 [500, 256, 8, 8] 0
41	Conv2d-38 [500, 256, 8, 8] 589,824
42	BatchNorm2d-39 [500, 256, 8, 8] 512
43	ReLU-40 [500, 256, 8, 8] 0
44	Conv2d-41 [500, 256, 8, 8] 589,824
45	BatchNorm2d-42 [500, 256, 8, 8] 512
46	ResidualBlock-43 [500, 256, 8, 8] 0
47	Conv2d-44 [500, 512, 4, 4] 1,179,648



48	BatchNorm2d-45	[500, 512, 4, 4]	1,024
49	ReLU-46	[500, 512, 4, 4]	0
50	Conv2d-47	[500, 512, 4, 4]	2,359,296
51	BatchNorm2d-48	[500, 512, 4, 4]	1,024
52	Conv2d-49	[500, 512, 4, 4]	131,072
53	BatchNorm2d-50	[500, 512, 4, 4]	1,024
54	ResidualBlock-51	[500, 512, 4, 4]	0
55	Conv2d-52	[500, 512, 4, 4]	2,359,296
56	BatchNorm2d-53	[500, 512, 4, 4]	1,024
57	ReLU-54	[500, 512, 4, 4]	0
58	Conv2d-55	[500, 512, 4, 4]	2,359,296
59	BatchNorm2d-56	[500, 512, 4, 4]	1,024
60	ResidualBlock-57	[500, 512, 4, 4]	0
61	Linear-58	[500, 10]	5,130
62	=====		
63	Total params: 11,173,962		
64	Trainable params: 11,173,962		
65	Non-trainable params: 0		
66	-----		
67	Input size (MB): 5.86		
68	Forward/backward pass size (MB): 6812.54		
69	Params size (MB): 42.63		
70	Estimated Total Size (MB): 6861.02		
71	-----		